



Master Informatique

“Preuve mécanisée de l’algorithme de Tarjan”

Rapport
en vue de la validation de
l'UE Initiation à la recherche

2019-2020

Étudiants : Angela Ipseiz
Maxime Nicolas
Matthieu Olejniczak

Encadrant : Monsieur MERZ

Décharge de responsabilités

L'Université de Lorraine n'entend donner ni approbation ni improbation aux opinions émises dans ce rapport, ces opinions devant être considérées comme propres à leur auteur.

Remerciements

Nous tenons à remercier toutes les personnes qui ont contribué au bon déroulement de notre travail et qui nous ont aidé lors de la rédaction de ce rapport.

Tout d'abord, nous adressons nos remerciements à notre encadrant, Monsieur Stephan Merz, enseignant chercheur au LORIA, pour son accueil, le temps passé ensemble, son écoute, ses conseils et ses interventions qui nous ont permis de progresser dans notre démarche et notre compréhension sur les preuves mécaniques. Il fut d'une aide précieuse dans les moments les plus délicats.

Enfin, nous tenons à remercier toutes les personnes qui nous ont conseillé et relu lors de la rédaction de ce rapport : nos familles, nos amis et surtout notre professeur de communication Madame Marie-Laure Alves.

Sommaire

| | |
|--|-----------|
| Sommaire | 5 |
| Introduction | 6 |
| I. Les outils utilisés | 7 |
| I.i. TLA+ | 7 |
| I.ii. PlusCal | 7 |
| I.iii. Model checker | 7 |
| I.iv. TLA+ proof system | 7 |
| II. Algorithme de Tarjan | 8 |
| II.i Description de l'algorithme | 8 |
| II.ii Fonctionnement de l'algorithme | 8 |
| II.iii Correction de l'algorithme | 8 |
| III. Preuve de l'algorithme de Tarjan | 9 |
| III.i Invariants | 9 |
| III.ii Preuve des invariants | 9 |
| IV. Problèmes et solutions apportées | 9 |
| Transcription de l'algorithme en TLA+ | 10 |
| Preuve de l'algorithme | 10 |
| Conclusion | 11 |
| Annexes | 12 |
| Bibliographie | 12 |

Introduction

« *Nous dépendons de plus en plus des logiciels, et il est important qu'ils fonctionnent de mieux en mieux.* »⁽¹⁾ déclare Leslie Lamport, pionnier de l'algorithme distribué et du concept de preuve algorithmique. En effet, les logiciels sont de plus en plus présents dans notre quotidien et pour certains, notre sécurité en dépend, comme les logiciels utilisés dans l'aviation ou le ferroviaire. De nos jours, un programme incertain, c'est-à-dire avec au moins une condition d'utilisation qui rend le résultat incorrect, peut engendrer d'énormes conséquences financières, humaines.... C'est pourquoi, il est impératif de réaliser des **preuves d'algorithmes**, notamment pour ceux qui sont liés directement à la sécurité, comme celles qui ont été faites pour l'automatisation de la ligne de métro 14 à Paris, ou le respect de la vie privée que doivent garantir les entreprises du Cloud.

Différents types d'algorithmes peuvent nécessiter une preuve. En effet, il existe des algorithmes impliquant des **graphes** qui sont au coeur de nombreux problèmes actuels. Par exemple, la résolution d'un sudoku peut être transformée en problème 2-SAT qui détermine s'il existe une solution possible grâce à des graphes. Il est des graphes, des structures de données représentées par un ensemble de sommets et d'arêtes. Un graphe est **orienté** si ses arêtes ne sont parcourables que dans un seul sens dont la direction est représentée par une flèche. Le problème 2-SAT utilise la décomposition en **composantes fortement connexes**. On appelle composantes fortement connexes un sous-graphe maximal G' d'un graphe orienté G tel que, pour tout couple (u,v) de noeuds de G , il existe un chemin de u à v . Ainsi, un graphe fortement connexe est un graphe formé d'une seule composante fortement connexe.

Pour les identifier, on peut utiliser différents algorithmes tels que l'algorithme de Kosaraju et l'**algorithme de Tarjan**, tous deux fondés sur un algorithme de parcours en profondeur en temps linéaire. La principale différence entre ces deux algorithmes est que celui de Tarjan identifie les composantes fortement connexes en parcourant une seule fois le graphe au lieu de deux pour celui de Kosaraju. Nous voulons ici nous intéresser à l'algorithme de Tarjan : Est-ce que l'algorithme de Tarjan nous donne l'ensemble des composantes fortement connexes quelque soit le graphe orienté sur lequel on l'applique ?

Pour répondre à cette problématique, nous regarderons dans un premier temps les outils que nous avons utilisés afin de réaliser cette preuve, ainsi que le bon fonctionnement de l'algorithme par le biais de l'outil TLA+. Ensuite, nous nous intéresserons à sa preuve. Enfin, nous étudierons les problèmes que nous avons rencontrés et comment nous les avons réglés.

I. Les outils utilisés

I.i. TLA+

TLA+⁽¹⁴⁾ est un langage de spécification, basé sur les mathématiques, permettant l'analyse et la description d'algorithmes au moyen de formules logiques. Créé par Leslie Lamport, il est utilisé dans l'environnement de développement toolbox TLA+. Cet environnement a pour but, à partir d'outils décrits dans les parties ci-dessous, de pouvoir connaître la correction des algorithmes et ainsi d'en faire leurs preuves.

Ce langage est la combinaison entre la théorie des ensembles - base des mathématiques classiques, servant à décrire les structures de données utilisées par un algorithme - et la logique temporelle, pour décrire les exécutions de l'algorithme. À ces bases classiques s'ajoute un langage simple de modules pour structurer une spécification. TLA+ ne possède pas de typage des variables mais fonctionne sur le principe de valeur de la variable aux différents états lors de l'exécution d'un algorithme. Si nous avons une variable i qui vaut 0 par exemple, dire que cette variable vaut 1 dans le prochain état revient à dire que i' vaut 1. C'est donc le caractère " ' " qui désigne la valeur de la variable qui la précède dans le prochain état.

Un algorithme en TLA+ est constitué d'un prédicat qui caractérise les états initiaux, habituellement appelé "Init", et un prédicat sur des couples d'états qui caractérise les transitions possibles d'un état à un autre, appelé "Next". Bien évidemment cette dernière peut faire appel à diverses autres fonctions définies précédemment dans le programme. En général, une spécification en TLA+ est de la forme $\text{Init} \wedge \Box[\text{Next}]_{\text{vars}} \wedge L$ où vars désigne la liste de toutes les variables utilisées dans la spécification et L est une formule temporelle qui exprime des contraintes supplémentaires sur les exécutions, typiquement des conditions d'équité pour demander que certaines actions possibles ne soit pas négligées. Quand il s'agit de démontrer la correction partielle d'un algorithme on n'a pas besoin de cette contrainte supplémentaire et on ne s'intéresse donc qu'à Init et Next.

I.ii. PlusCal

Exprimer un algorithme en TLA+ peut s'avérer compliqué, c'est pourquoi Lamport a créé le langage PlusCal. C'est un langage algorithmique similaire au pseudo-code. Les expressions de PlusCal sont celles de TLA+ et la sémantique de PlusCal est donnée par le traducteur d'algorithmes PlusCal en TLA+. Ce langage permet de transcrire des algorithmes pseudo-code en TLA+. PlusCal est souvent plus compréhensible notamment pour les débutants car celui-ci se rapproche plus d'un langage de programmation classique.

PlusCal et TLA+ sont donc souvent utilisés ensemble pour faire de la vérification de spécifications.

I.iii. Model checker

Le *model checker* est un outil de la toolbox TLA+ permettant de montrer la correction de l'algorithme sur des exemples concrets en utilisant des modèles. La vérification de modèle repose sur le calcul du graphe des états accessibles à partir d'un modèle donné, c'est-à-dire qu'à partir d'un état de l'exécution du programme, le model checker va créer un graphe contenant tous les états successeur possibles à partir de l'état courant. C'est à l'aide de cela (et d'un modèle) que l'on peut savoir si un algorithme fonctionne pour un exemple concret.

Là où prouver formellement un programme peut être long et exiger beaucoup de ressources, la vérification de modèle est très souvent une alternative employée car moins coûteuse. Cependant, elle ne suffit pas à montrer que l'algorithme est correct pour tous les cas car il existe une infinité d'exemples possibles et certains exemples demandent beaucoup de ressources et de temps de calcul pour que cela puisse être possible. Par contre, on peut gagner en confiance en utilisant du model checking avant d'entamer la preuve formelle d'un algorithme.

I.iv. TLA+ proof system

TLA+ proof system₍₁₅₎ est une extension de TLA+ permettant de faire des preuves formelles mécanisées d'algorithme. Il a été développé par un laboratoire de Microsoft Research et Inria Paris avec la collaboration d'une équipe de recherche du Loria. Il est composé de quatre outils de preuve semi-automatiques, appelés aussi *provers* : smt, Zenon, Isabelle et PTL.

L'assistant à la preuve offre la possibilité de vérifier formellement, à l'aide de ces prouveurs, les clauses que l'on veut montrer en utilisant des définitions ou d'autres morceaux de preuves que l'on a ou que l'on veut démontrer. Une preuve peut être décomposée grâce à un langage hiérarchique de preuve qui sert à développer une preuve interactive. En effet, si un cas que nous cherchons à prouver ne fonctionne pas tout seul, nous pouvons décomposer celui-ci en divers sous-cas qu'il faudra montrer et qui permettront d'arriver à montrer que le cas initial est juste.

- Ajouter exemple simple


Ces outils forment la pierre angulaire de notre sujet de recherche. Nous allons les utiliser pour démontrer le bon fonctionnement de l'algorithme de Tarjan.

II. Algorithme de Tarjan

II.i Graphe et composante connexe

Avant de travailler sur l'algorithme de Tarjan en lui-même, nous avons testé le logiciel TLA+ et certaines de ses limites en implémentant une recherche de composantes fortement connexes, aussi appelées SCC (Strongly Connected Component).

Pour cela, nous avons dû définir les notions essentielles telles qu'un *chemin*, *deux sommets connectés*, *un ensemble de sommets connectés*, ainsi qu'une *composante fortement connexe*. Un chemin est défini par un sommet de départ, un sommet d'arrivée, et sa taille. Il indique si, en partant du sommet de départ, on peut atteindre au sommet d'arrivée en un certain nombre de sauts. Deux sommets sont connectés s'il existe un chemin entre eux-ci. Un ensemble de sommets sont connectés si, en prenant tous les sommets de l'ensemble deux à deux, ceux-ci sont connectés. Pour finir, un ensemble de sommets est une SCC si tous les sommets sont connectés et cet ensemble est de taille maximale.



Graphe orienté construit avec VisuAlgo₍₁₆₎

Voici un graphe orienté contenant 5 nœuds. On veut connaître les composantes fortement connexes de celui-ci. Le sommet 0 n'a aucun prédécesseur. Il forme alors un SCC à lui tout seul, aucun autre sommet ne peut l'atteindre. On peut apercevoir que les sommets 1, 2 et 3 forment un triangle. Le sommet 2 est un successeur du sommet 1, qui lui est un successeur du sommet 3, lui-même successeur du sommet 2. Ces trois sommets sont alors connectés entre eux : c'est une composante connexe. En effet, la composante n'est pas fortement connexe car le sommet 4 est un successeur du sommet 3 et prédécesseur du

sommet 2. Les sommets 2 et 3 se trouvent déjà dans une composante, le sommet 4 peut alors aussi en faire parti. On obtient à ce moment une composante fortement connexe. Les SCCs de ce graphe sont donc les ensembles $\{0\}$ et $\{1, 2, 3, 4\}$.

II.ii Description et fonctionnement de l'algorithme

Avant de décrire l'algorithme, il convient de s'intéresser aux variables que nous allons utiliser.

```
variables
    index = 0,
    t_stack = << >>,
    num = [n \in Nodes |-> -1],
    lowlink = [n \in Nodes |-> -1],
    onStack = [n \in Nodes |-> FALSE],
    sccs = {},
    toVisit = Nodes;
```

- **Index** correspond à l'index du sommet visité.
- **t_stack** est la pile sur laquelle on place les sommets en cours de visite.
- La variable **num** nous donne à la fois le numéro du noeud et son état. En effet, s'il n'a pas encore été exploré, elle vaut -1.
- **lowlink** représente le plus petit index du sommet atteignable par le noeud courant entre ses descendants et lui-même.
- **onStack**, comme son nom l'indique, permet de savoir si un sommet est déjà sur t_stack.
- **sccs** est l'ensemble des composantes fortement connexes retourné par l'algorithme.
- **toVisit** est l'ensemble des sommets qui n'ont pas encore eu de numéro, donc qui n'ont pas encore été visités.

La fonction **main** de l'algorithme sera assez simple :

```
main:
    while (toVisit # {}) {
        with (n \in toVisit) {
            toVisit := toVisit \ {n};
            if (num[n] = -1) { call visit(n) }
        }
    }
}
```

Au début de l'algorithme, toVisit est composé de tous les sommets du graphe donnés en entrée. La fonction main fait que, tant que toVisit n'est pas vide, on sélectionne un sommet n de toVisit qu'on retire de cet ensemble, puis on effectue la procédure visit() sur ce sommet.

Comme son nom l'indique, la procédure **visit(Node)** effectue une visite sur le noeud donné en paramètre.

Chaque visite d'un sommet v commence par une initialisation des variables dans une fonction **start_visit**.

```
start_visit:
    num[v] := index;
    lowlink[v] := index;
    index := index+1;
    t_stack := <<v>> \o t_stack;
    onStack[v] := TRUE;
    succs := Succs[v];
```

La ligne `t_stack := <<v>> \o t_stack` veut dire que l'on place le noeud courant v au sommet de la pile t_stack.

Après avoir initialisé les variables, on cherche les successeurs.

```
explore_succ:
    while (succs # {}) {
        with (s \in succs) { w := s; succs := succs \ {s} };
        if (num[w] = -1) {
visit_recurse:
            call visit(w);
continue_visit:
            if (lowlink[w] < lowlink[v]) { lowlink[v] := lowlink[w] }
        } else if (onStack[w]) {
            if (num[w] < lowlink[v]) { lowlink[v] := num[w] }
        }
    };
```

```

check_root:
  if (lowlink[v] = num[v] /\ (\E k \in 1 .. Len(t_stack) : t_stack[k] = v)) {
    \* new SCC found: pop all nodes up to v from the (Tarjan) stack
    with (k = CHOOSE k \in 1 .. Len(t_stack) : t_stack[k] = v) {
      sccs := sccs \cup {{t_stack[i] : i \in 1 .. k}};
      onStack := [n \in Nodes |-> IF \E i \in 1 .. k : n = t_stack[i] THEN FALSE
                  ELSE onStack[n]];
      t_stack := SubSeq(t_stack, k+1, Len(t_stack))
    }
  };
  return;
}

```

Nous regardons donc le successeur et avons deux choix :

- S'il n'a pas encore été visité, alors on le visite. On fait donc une récursion grâce à la fonction **visit_recurse**.
Puis, une fois que l'on a plus de successeurs à visiter, on entre dans **continue_visit**.
Si le plus petit sommet accessible par le noeud successeur est inférieur au plus petit sommet accessible par le noeud courant, alors le lowlink du noeud courant prend la valeur du lowlink du successeur.
- Si le noeud successeur a déjà été visité, donc s'il fait partie de la SCC actuelle, et que son numéro est inférieur au lowlink du noeud courant, alors le lowlink du noeud courant prend cette valeur.

Enfin, il ne nous reste plus qu'à traiter toutes les informations obtenues avec **check_root**.

Si le noeud courant est une racine (lowlink = num) et qu'il est déjà sur la pile, alors on a trouvé une composante fortement connexe. Il ne reste plus qu'à dépiler jusqu'à l'instance du noeud sur la pile, en ajoutant les sommets rencontrés dans l'ensemble des SCC.

II.iii L'algorithme en TLA+

L'algorithme donné précédemment est la version Pluscal de l'algorithme de Tarjan. Nous avons utilisé la toolbox pour le transcrire en version TLA+.

Dans cette nouvelle version, on commence par la procédure Init, où l'on initialise nos variables.

De plus, viennent principalement deux nouvelles variables : *stack* et *pc*.

Comme on peut le voir dans les images suivantes, pc nous indique quelle procédure effectuer.

```
start_visit == /\ pc = "start_visit"
              /\ num' = [num EXCEPT ![v] = index]
```

```
explore_succ == /\ pc = "explore_succ"
                /\ IF succs # {}
```


Quant à la variable stack, il s'agit d'une pile utilisée pour effectuer des appels récurifs.

II.iv Vérification du modèle de l'algorithme

- Utilisation du model checker sur des exemples concrets
- Résultats du model checker
- Montrez aussi la propriété de correction (partielle) de l'algorithme, c'est à dire qu'à la fin de l'algorithme la variable sccs contient précisément les composants fortement connexes du graphe. Il serait aussi intéressant de montrer l'explosion du nombre d'états avec la taille du graphe.

REEMPLACER L'EXEMPLE SUIVANT DU SCC PAR CELUI DE TARJAN

Nous avons testé l'algorithme sur un exemple en utilisant le Model checker pour vérifier ses limites. On a alors créé un modèle composé de quelques sommets et arêtes.



Graphe orienté construit avec VisuAlgo₍₁₆₎

Avec les constantes Nodes et Edge(.,.), le modèle de ce graphe se construit de la façon suivante :

- Nodes <- {0, 1, 2, 3, 4}
- Edge(m, n) <- $\bigvee m = 1 \wedge n = 0$
 $\bigvee m = 1 \wedge n = 2$
 $\bigvee m = 2 \wedge n = 3$
 $\bigvee m = 3 \wedge n = 1$
 $\bigvee m = 3 \wedge n = 4$
 $\bigvee m = 4 \wedge n = 2$

On veut savoir si l'ensemble {1, 2, 3} est un SCC, c'est-à-dire $\text{SCC}(\{1,2,3\})$. Il y a peu de sommets, le model checker est alors rapide à donner une réponse. Celle-ci est négative dans ce cas. En effet, cet ensemble n'est pas le plus grand possible car le sommet 4 a aussi accès à n'importe quel sommet de l'ensemble, et n'importe quel sommet de l'ensemble a accès à 4. $\text{SCC}(\{1,2,3,4\})$ retourne alors TRUE.

Dans un deuxième temps, on ajoute 5 sommets isolés à ce graphe. Bien qu'ils soient isolés et n'ont alors aucune influence, le model checker va tout de même vérifier tous les sommets existants, ce qui va drastiquement augmenter le temps de calcul. Pour seulement quelques petites secondes de recherche lorsque le graphe possède 5 sommets, plusieurs heures ne suffisent pas à terminer la recherche avec un graphe à 10 sommets.

Désormais, nous avons pu nous faire une idée quant au fonctionnement de l'algorithme et à la validité des résultats qu'il renvoi. Cependant, cela ne montre pas que ceux-ci seront toujours bons. Voilà pourquoi, nous devons approfondir avec une preuve formelle de l'algorithme.

III. Preuve de l'algorithme de Tarjan

(énoncer quelque part la vraie propriété de correction -> à la fin retourne l'ensemble des composantes fortement connexes)

III.i Invariants

Un invariant de boucle est une propriété qui est vraie avant, pendant et après une boucle, soit à tout moment de l'algorithme, à condition que l'algorithme consiste en une seule boucle. Ici la structure est plus complexe, et on parle d'invariant d'algorithme – un prédicat qui est vrai tout au long de l'exécution. Les invariants peuvent être plutôt généraux, par exemple à tout état du déroulement de l'algorithme, un numéro de noeud est un entier, ou plus restreint, comme les numéros des noeuds qui valent -1 en début d'algorithme. Un invariant permet alors de montrer qu'une propriété est valide pour tout état. Plusieurs invariants ont alors été prouvés pour montrer le bon fonctionnement de l'algorithme.

Dans la preuve de l'algorithme de Tarjan, nous nous sommes inspirés du travail de l'équipe Veridis du Loria pour écrire les invariants.⁽⁷⁾ En effet, cette équipe a déjà fait la preuve de cet algorithme mais à l'aide d'autres outils tels que Why3, Isabelle et Coq, qui sont également des assistants à la preuve. Nous nous servons donc des invariants qui ont été réalisés pour la preuve précédente afin de réaliser la preuve en TLA+. Bien évidemment, nous devons rechercher comment transformer ces invariants pour qu'ils soient adaptés au langage TLA+ et à l'algorithme correspondant, car il peut y avoir des différences d'implémentation. En effet Why3, Isabelle et Coq sont basés sur des représentations de l'algorithme sous la forme de fonctions récursives (OCaml par exemple) alors que la formulation en PlusCal est un programme impératif.

III.ii Preuve des invariants

->Parler d'accessibilité de noeuds dans le graphe (car on parle de SCC)

Maintenant qu'on a montré l'utilité des invariants, il faut les prouver. On part d'invariants très généraux auxquels on ajoute des informations supplémentaires pour les affiner. L'objectif est de démontrer que la correction de l'algorithme découle de l'invariant. Il faut alors accumuler assez d'informations pour discuter l'état final. La séparation des invariants est intéressante, car dans un premier temps il est très complexe de trouver l'invariant intégral dès le début, mais aussi parce qu'on a rarement besoin de revenir sur les précédents une fois qu'ils ont été prouvés, ou du moins on essaie de modifier un invariant trop fréquemment. On peut alors se servir de ceux-ci une fois prouvés pour démontrer les

suivants. Nous avons utilisé 4 invariants dans ce projet, bien qu'il en existe d'autres, qui sont :

- L'invariant de typage
- L'invariant des sommets sur la pile
- L'invariant des couleurs
- L'invariant de liaison entre les piles

-> Expliquer ce que les invariants montrent

Pour faire la preuve d'un invariant, il faut prouver le théorème correspondant. Ce théorème dit que pour n'importe quel état de l'algorithme, à partir de l'état initial et pour n'importe quel état suivant, toutes les clauses de l'invariant doivent être satisfaites, c'est-à-dire que chaque élément de l'invariant doit être correct.

Pour prouver ce théorème, il faut décomposer le théorème en deux sous-parties. Pour la première, il faut montrer que l'invariant est correct pour l'état initial. La deuxième sous-partie consiste à prouver que l'invariant est correct dans l'état suivant en sachant qu'il est vrai dans l'état courant et en connaissant les états suivants possibles. Si nous sommes en train de prouver un n-ième invariant, nous avons donc n-1 invariants prouvés. Nous pouvons alors utiliser ces n-1 invariants pour nous aider à prouver le n-ième. Grâce à cela, nous pouvons commencer par décomposer un invariant qui peut être grand et difficile à montrer en plusieurs invariants plus simples pour ensuite les utiliser dans la preuve d'autres invariants.

III.iii Invariant et correction

Un algorithme est correct s'il fait ce qu'on attend de lui. C'est à dire qu'il faut que son exécution termine, et que son état final nous donne le résultat que nous attendons. Sachant que l'algorithme de Tarjan est une énorme boucle, un invariant a donc le rôle idéal ici. En effet, un invariant montre qu'un ensemble de propriétés est vrai à n'importe quel état, et que si celui-ci est démontré, alors l'exécution s'est déroulée comme nous le souhaitons. Par définition de l'algorithme de Tarjan, l'algorithme finit quand la boucle principale finit. Ainsi, si on a un invariant témoignant de la validité des résultats obtenus en fin de boucle et que cet invariant est prouvé, alors l'algorithme de Tarjan est démontré.

III.iv Terminaison de l'algorithme

Par manque de temps, nous n'avons pu prouver la terminaison de l'algorithme. Cependant, cela ne nous empêche pas d'avoir une idée sur comment la démontrer. Sachant que l'algorithme s'arrête seulement lorsqu'il n'y a plus de sommet ayant pour numéro -1, et qu'il parcourt tous les sommets en leur adressant un numéro dès qu'il les

rencontre, on remarque que l'algorithme s'arrêtera donc une fois qu'il aura parcouru tous les sommets du graphe.

Ainsi la réponse à la question "L'algorithme finit-il ?" est assez intuitive. C'est pourquoi, on comprend tout de suite que l'essentiel et la difficulté de la preuve réside dans le fait de montrer qu'à la fin de l'algorithme, nous obtenons bien le résultat attendu, c'est-à-dire l'ensemble des composantes fortement connexes du graphe.

IV. Problèmes et solutions apportées

IV. i Transcription de l'algorithme en TLA+

Notre premier projet après la compréhension des outils utilisés fut la transcription de l'algorithme de Tarjan en langage reconnu par TLA+. Cependant, les multiples boucles ont fait l'objet de différents problèmes, car le langage TLA+ ne permet pas de faire de la récursivité, il est donc impossible de traduire l'algorithme tel qu'il est écrit en langage naturel. Nous avons donc utilisé l'outil décrit précédemment, PlusCal, pour transcrire un algorithme initialement récursif en TLA+.

IV.ii Preuve de l'algorithme

- difficultés pour les parties reposants sur le fonctionnement de la pile
- Renforcement des invariants
- énoncer un cas complexe de preuve ?

Conclusion

Il est facile de comprendre le fonctionnement superficiel d'un programme, mais il est difficile de comprendre son fonctionnement dans les moindres détails - comment il arrive à certains résultats - et c'est notamment cela qu'il faut savoir pour réussir à prouver qu'il fonctionnera dans tous les cas. Au mieux, on peut s'informer sur les résultats qu'il peut donner en utilisant des outils comme un model checker. Mais ceci ne suffit pas. Comme nous l'avons vu, ces outils ont leurs limites. Par exemple, pour l'algorithme de Tarjan, nous ne pouvons avoir un retour que sur des petits graphes. Ainsi, il est très compliqué de savoir s'il fonctionne et finit sur un graphe avec plus d'une centaine de nœuds et il est impossible de tester tous les graphes possibles car il en existe une infinité. Cependant, même si cela permet d'avoir une idée sur la correction du programme, encore reste-t-il à la prouver. Pour ce faire, nous avons vu que l'on peut utiliser des logiciels de preuve semi-automatique comme TLA+ proof system, un outil associé à TLA+. Bien qu'ils soient d'une grande aide pour avoir une idée de ce qu'il faut prouver, ils ne nous indiquent pas comment le faire.

Malgré ces outils, la construction d'assertions intermédiaires, comme les invariants mais aussi la décomposition d'une étape de la preuve, continuent de se faire de manière empirique. Par exemple, lorsque l'on veut prouver un invariant, on peut se rendre compte assez vite que l'on est bloqué, qu'il nous manque quelque chose pour avancer et donc on se retrouve obligé de lui rajouter de nouvelles conditions, de le rendre plus strict. Évidemment, ce que l'on ajoute doit être à nouveau prouvé. C'est donc ici que l'on fait un pas en arrière pour pouvoir continuer à avancer. Et des pas en arrière, nous en avons fait quelques uns lors de la preuve de l'algorithme de Tarjan, mais qui nous ont permis de faire beaucoup de pas en avant dans notre preuve. Nous avons donc pu faire une partie de la preuve de l'algorithme de Tarjan.

L'algorithme de Tarjan n'est qu'un cas d'étude. Il existe des algorithmes et des programmes bien plus compliqués à prouver. Cependant, certaines méthodes, comme celle que nous avons utilisée, peuvent et doivent leur être appliquées. En effet, si nous développons un algorithme qui va être utilisé pour gérer le trafic ferroviaire, il est nécessaire de s'assurer qu'il fonctionne dans n'importe quelle situation. Fort heureusement, le domaine de la preuve est un domaine émergent sur lequel des centres de recherches développent des outils de preuve plus puissants, c'est pourquoi nous pouvons espérer un jour savoir pertinemment ce que l'on fait.

Ce projet d'initiation à la recherche nous a donc permis de mieux comprendre le domaine de la preuve algorithmique, son importance et le besoin que nous en avons aujourd'hui. De plus, nous avons pu apprendre à faire une telle preuve sur un algorithme classique, et même si nous n'avons pas pu la faire entièrement, ceci fut une très bonne expérience.

Annexes

Bibliographie

- (1) https://www.lemonde.fr/sciences/article/2014/06/16/leslie-lamport-un-informaticien-dans-le-s-nuages_4439171_1650684.html
- (2) https://fr.wikipedia.org/wiki/Qualit%C3%A9_logicielle
- (3) https://fr.wikipedia.org/wiki/Graphe_orient%C3%A9
- (4) <http://zanotti.univ-tln.fr/ALGO/I31/Complexite.html#def:successeur>
- (5) https://tla.msr-inria.inria.fr/tlaps/content/Documentation/Tutorial/The_example.html
- (6) <https://lamport.azurewebsites.net/tla/tla.html>

Références du sujet

- (7) [Représentation de l'algorithme de Tarjan par l'équipe du Loria] Ran Chen, Cyril Cohen, Jean-Jacques Lévy, Stephan Merz, Laurent Théry. Formal Proofs of Tarjan's Strongly Connected Components Algorithm in Why3, Coq and Isabelle. 10th Intl. Conf. Interactive Theorem Proving (ITP). Leibniz Intl. Proc. in Informatics, 2019.
<http://drops.dagstuhl.de/opus/volltexte/2019/11068/>
- (8) [Assistant à la preuve Why3] François Bobot, Jean-Christophe Filliâtre, Claude Marché, Guillaume Melquiond, Andrei Paskevich. The Why3 platform, version 0.86.1. Technical Report, LRI, CNRS, Univ. Paris Sud, Inria Saclay, May 2015.
<http://toccata.lri.fr/gallery/why3.en.html>.
- (9) [Assistant à la preuve Coq] The Coq Development Team. The Coq Proof Assistant v.8.3. Reference Manual. Inria, 2010. <http://coq.inria.fr/>
- (10) [TLAPS] TLA+ Proofs. Denis Cousineau, Damien Doligez, Leslie Lamport, Stephan Merz, Daniel Ricketts, Hernán Vanzetto. 18th Intl. Symp. Formal Methods (FM). Springer LNCS 7436, pp. 147-154. Paris, France, 2012.
- (11) [TLA+] Leslie Lamport. Specifying Systems. Addison Wesley (Boston, Mass.), 2002.
<http://lamport.azurewebsites.net/tla/tla.html> .
- (12) [Assistant à la preuve Isabelle] Tobias Nipkow, Lawrence Paulson, Markus Wenzel. Isabelle/HOL. A Proof Assistant for Higher-Order Logic. Springer LNCS 2283, 2002.
- (13) [Tarjan] Robert Tarjan. Depth first search and linear graph algorithms. SIAM Journal on Computing, 1972.
- (14) A High-Level View of TLA+, Leslie Lamport, 2018
<https://lamport.azurewebsites.net/tla/high-level-view.html>

(15) <https://tla.msr-inria.inria.fr/tlaps/content/Home.html>

(16) Visualiseur de graphes <https://visualgo.net/en/dfsdfs>

Déclaration sur l'honneur contre le plagiat

Je soussignée,

Ipsreiz Angela

Régulièrement inscrit à l'Université de Lorraine

N° de carte d'étudiant : 31608993

Année universitaire : 2019-2020

Niveau d'études : M

Parcours : Informatique

N° UE : 811

Certifie qu'il s'agit d'un travail original et que toutes les sources utilisées ont été indiquées dans leur totalité. Je certifie, de surcroît, que je n'ai ni recopié ni utilisé des idées ou des formulations tirées d'un ouvrage, article ou mémoire, en version imprimée ou électronique, sans mentionner précisément leur origine et que les citations intégrales sont signalées entre guillemets.

Conformément à la loi, le non-respect de ces dispositions me rend passible de poursuites devant la commission disciplinaire et les tribunaux de la République Française.

Fait à Vandœuvre-lès-Nancy, le.....

Signature :

A handwritten signature in black ink, appearing to read 'Ipsreiz', written in a cursive style.

Déclaration sur l'honneur contre le plagiat

Je soussigné,

Nicolas Maxime

Régulièrement inscrit à l'Université de Lorraine

N° de carte d'étudiant : 31509056

Année universitaire : 2019-2020

Niveau d'études : M

Parcours : Informatique

N° UE : 811

Certifie qu'il s'agit d'un travail original et que toutes les sources utilisées ont été indiquées dans leur totalité. Je certifie, de surcroît, que je n'ai ni recopié ni utilisé des idées ou des formulations tirées d'un ouvrage, article ou mémoire, en version imprimée ou électronique, sans mentionner précisément leur origine et que les citations intégrales sont signalées entre guillemets.

Conformément à la loi, le non-respect de ces dispositions me rend passible de poursuites devant la commission disciplinaire et les tribunaux de la République Française.

Fait à Vandoeuvre-lès-Nancy, le XX avril 2020

Signature :

A handwritten signature in black ink, appearing to read 'Nicolas', with a stylized flourish at the end.

Déclaration sur l'honneur contre le plagiat

Je soussigné,

Olejniczak Matthieu

Régulièrement inscrit à l'Université de Lorraine

N° de carte d'étudiant : 31506421

Année universitaire : 2019-2020

Niveau d'études : M

Parcours : Informatique

N° UE : 811

Certifie qu'il s'agit d'un travail original et que toutes les sources utilisées ont été indiquées dans leur totalité. Je certifie, de surcroît, que je n'ai ni recopié ni utilisé des idées ou des formulations tirées d'un ouvrage, article ou mémoire, en version imprimée ou électronique, sans mentionner précisément leur origine et que les citations intégrales sont signalées entre guillemets.

Conformément à la loi, le non-respect de ces dispositions me rend passible de poursuites devant la commission disciplinaire et les tribunaux de la République Française.

Fait à Vandœuvre-lès-Nancy, le.....

Signature :



(Quatrième de couverture)

Depuis l'essor du numérique, les logiciels ont pris de plus en plus de place dans notre vie et notre quotidien. En plus de leur importance, le nombre de lignes de code qui les compose continue de grandir lui aussi, augmentant la possibilité d'avoir des erreurs. Plus un logiciel est employé à de grandes fins, plus une erreur aura de répercussions. Ainsi il devient important de vérifier qu'un logiciel termine et fonctionne correctement.

Pour effectuer cette vérification, plusieurs méthodes et outils ont été inventés tels que la vérification de modèle et la preuve formelle. Ce sont les deux procédés que nous présenterons et appliquerons, ici, à l'algorithme de Tarjan, notre cas d'étude.

Since the rise of digital technologies, softwares have become increasingly important in our everyday life. With a software's value increasing, the amount of lines of code, making it, is growing too, which further expands the risk of mistakes. The more far-reaching a software is, the greater the effect of errors will be. So it is important to ascertain that it ends and works correctly.

To do this, there are several methods and tools that have been invented like the property checking method and the Formal proof method. That's the two procedures we are introducing and using, here, at Tarjan's algorithm, our case study.